API CountTokens

L'API CountTokens calcule le nombre de jetons d'entrée avant d'envoyer une requête à l'API Gemini.

Utilisez l'API CountTokens pour éviter que les requêtes ne dépassent la fenêtre de contexte du modèle et estimer les coûts potentiels en fonction des caractères ou jetons facturables.

L'API CountTokens peut utiliser le même paramètre `contents` que les requêtes d'inférence de l'API Gemini.

Modèles compatibles

- Image Gemini 3.1 Flash (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/3-1-flash-image?hl=fr)
- Gemini 3.1 Pro (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/3-1-pro?hl=fr)
- Gemini 3 Flash (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/3-flash?hl=fr)
- Gemini 3 Pro (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/3-pro?hl=fr)
- Image Gemini 3 Pro (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/3-pro-image?hl=fr)
- Gemini 2.5 Pro (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-pro?hl=fr)
- Gemini 2.5 Flash (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash?hl=fr)
- Gemini 2.5 Flash-Lite (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-lite?hl=fr)

- Gemini 2.5 Flash Image (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-image?hl=fr)
- Gemini 2.5 Flash (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash?hl=fr)
- Gemini 2.5 Flash-Lite (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-lite?hl=fr)
- Gemini 2.0 Flash (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-0-flash?hl=fr)
- Gemini 2.0 Flash-Lite (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-0-flash-lite?hl=fr)

Liste des paramètres

Cette classe comprend deux propriétés principales : `role` et `parts`. La propriété `role` indique la personne qui produit le contenu, tandis que la propriété `parts` contient plusieurs éléments, chacun représentant un segment de données dans un message.

Paramètres	
`role`	Facultatif : `string` Identité de l'entité qui crée le message. Définissez cette chaîne sur l'une des valeurs suivantes : • `user` : indique que le message est envoyé par une personne réelle. Par exemple, un message généré par l'utilisateur. • `model` : indique que le message est généré par le modèle. La valeur `model` permet d'insérer des messages du modèle dans des conversations multitours. Pour les conversations à un seul tour, laissez ce champ vide ou ne le définissez pas.
`parts`	`part` Liste de parties ordonnées qui composent un seul message. Chaque partie peut avoir un type MIME IANA (https://www.iana.org/assignments/media-types/media-types.xml) différent.

`Part`

Type de données comportant du contenu multimédia qui fait partie d'un message `Content` en plusieurs parties.

Paramètres

`text`	Facultatif : `string` Prompt textuel ou extrait de code.
`inline_data`	Facultatif : `Blob` Données intégrées dans des octets bruts.
`file_data`	Facultatif : `FileData` Données stockées dans un fichier.

`Blob`

Blob de contenu. Si possible, envoyez le message sous forme de texte plutôt que d'octets bruts.

Paramètres

`mime_type`	`string` Type MIME IANA (https://www.iana.org/assignments/media-types/media-types.xml) des données.
`data`	`bytes` Octets bruts.

`FileData`

Données basées sur l'URI.

Paramètres

`mime_type`	`string`

	Type MIME IANA (https://www.iana.org/assignments/media-types/media-types.xml) des données.
`file_uri`	`string` URI Cloud Storage du fichier stockant les données.

`system_instruction`

Ce champ correspond aux `system_instructions` fournies par l'utilisateur. Il est identique à `contents`, mais accepte moins de types de contenu.

Paramètres

`role`	`string` Type MIME IANA (https://www.iana.org/assignments/media-types/media-types.xml) des données. Ce champ est ignoré en interne.
`parts`	`Part` Texte uniquement. Instructions que les utilisateurs souhaitent transmettre au modèle.

`FunctionDeclaration`

Représentation structurée d'une déclaration de fonction telle que définie par la spécification OpenAPI 3.0 (https://spec.openapis.org/oas/v3.0.3), qui représente une fonction pour laquelle le modèle peut générer des entrées JSON.

Paramètres

`name`	`string` Nom de la fonction à appeler.
`description`	Facultatif : `string` Description et objectif de la fonction.
`parameters`	Facultatif : `Schema` Décrit les paramètres de la fonction au format d'objet Schema JSON OpenAPI (spécification OpenAPI 3.0

	(https://spec.openapis.org/oas/v3.0.3)).
`response`	Facultatif : `Schema` Décrit la sortie de la fonction au format d'objet Schema JSON OpenAPI (spécification OpenAPI 3.0 (https://spec.openapis.org/oas/v3.0.3)).

Exemples

Obtenir le nombre de jetons d'un prompt textuel

Cet exemple compte les jetons d'un seul prompt textuel :

REST | Python Gen AI SDK | Go Gen AI SDK | Node.js Gen AI SDK | Java Gen AI SDK

Pour obtenir le nombre de jetons et le nombre de caractères facturables d'un prompt à l'aide de l'API Vertex AI, envoyez une requête `POST` au point de terminaison du modèle d'éditeur.

Avant d'utiliser les données de requête, effectuez les remplacements suivants :

- *LOCATION* : région dans laquelle traiter la requête. Les options disponibles incluent les suivantes :

  Cliquer pour développer la liste partielle des régions disponibles

  - `us-central1`
  - `us-west4`
  - `northamerica-northeast1`
  - `us-east4`
  - `us-west1`
  - `asia-northeast3`
  - `asia-southeast1`
  - `asia-northeast1`
- *PROJECT_ID* : ID de votre projet. (https://docs.cloud.google.com/resource-manager/docs/creating-managing-projects?hl=fr#identifiers)

- ***MODEL_ID*** : ID du modèle multimodal que vous souhaitez utiliser.
- ***ROLE*** : rôle dans une conversation associée au contenu. La spécification d'un rôle est requise, même dans les cas d'utilisation à un seul tour. Les valeurs acceptées incluent les suivantes :
  - `USER` : spécifie le contenu que vous envoyez.
- ***TEXT*** : instructions textuelles à inclure dans le prompt.

Méthode HTTP et URL :

```
POST https://LOCATION-aiplatform.googleapis.com/v1/projects/PROJECT_I
```

Corps JSON de la requête :

```
{
  "contents": [{
    "role": "ROLE",
    "parts": [{
      "text": "TEXT"
    }]
  }]
}
```

Pour envoyer votre requête, choisissez l'une des options suivantes :

curlPowerShell (#powershell)
(#curl)

★ **Remarque** : Pour la commande suivante, nous partons du principe que vous vous êtes connecté à la CLI **`gcloud`** avec votre compte utilisateur en exécutant la commande **`gcloud init`** (https://docs.cloud.google.com/sdk/gcloud/reference/init?hl=fr) ou **`gcloud auth login`** (https://docs.cloud.google.com/sdk/gcloud/reference/auth/login?hl=fr), ou en utilisant Cloud Shell (https://docs.cloud.google.com/shell/docs?hl=fr), qui vous connecte automatiquement à la CLI **`gcloud`**. Vous pouvez exécuter la commande **`gcloud auth list`** (https://docs.cloud.google.com/sdk/gcloud/reference/auth/list?hl=fr) pour vérifier quel est le compte actuellement actif.

Enregistrez le corps de la requête dans un fichier nommé **`request.json`**, puis exécutez la commande suivante :

```
curl -X POST \
     -H "Authorization: Bearer $(gcloud auth print-access-token)"
     -H "Content-Type: application/json; charset=utf-8" \
     -d @request.json \
     "https://LOCATION -aiplatform.googleapis.com/v1/projects/PR
```

Vous devriez recevoir une réponse JSON semblable à la suivante.

Réponse

```
{
  "totalTokens": 31,
  "totalBillableCharacters": 96,
  "promptTokensDetails": [
    {
      "modality": "TEXT",
      "tokenCount": 31
    }
  ]
}
```

Obtenir le nombre de jetons d'un prompt multimédia

Cet exemple compte les jetons d'un prompt utilisant différents types de contenus multimédias.

REST | Python Gen AI SDK | Go Gen AI SDK | Node.js Gen AI SDK | Java Gen AI SDK

Pour obtenir le nombre de jetons et le nombre de caractères facturables d'un prompt à l'aide de l'API Vertex AI, envoyez une requête `POST` au point de terminaison du modèle d'éditeur.

Avant d'utiliser les données de requête, effectuez les remplacements suivants :

- *LOCATION* : région dans laquelle traiter la requête. Les options disponibles incluent les suivantes :

  Cliquer pour développer la liste partielle des régions disponibles

  - `us-central1`
  - `us-west4`
  - `northamerica-northeast1`
  - `us-east4`
  - `us-west1`
  - `asia-northeast3`
  - `asia-southeast1`
  - `asia-northeast1`
- *PROJECT_ID* : .
- *MODEL_ID* : ID du modèle multimodal que vous souhaitez utiliser.
- *ROLE* : rôle dans une conversation associée au contenu. La spécification d'un rôle est requise, même dans les cas d'utilisation à un seul tour. Les valeurs acceptées incluent les suivantes :
  - `USER` : spécifie le contenu que vous envoyez.
- *TEXT* : instructions textuelles à inclure dans le prompt.
- *FILE_URI* : URI ou URL du fichier à inclure dans le prompt. Les valeurs acceptées incluent les suivantes :
  - **URI du bucket Cloud Storage** : l'objet doit être lisible publiquement ou se trouver dans le même projet Google Cloud que celui qui envoie la requête. La taille limite pour `gemini-2.0-flash` et `gemini-2.0-flash-lite` est de 2 Go.
  - **URL HTTP** : l'URL du fichier doit être lisible publiquement. Vous pouvez spécifier un fichier vidéo, un fichier audio et jusqu'à 10 fichiers image par requête. Les fichiers audio, les fichiers vidéo et les documents ne doivent pas dépasser 15 Mo.
  - **URL de la vidéo YouTube** : la vidéo YouTube doit appartenir au compte que vous avez utilisé pour vous connecter à la console Google Cloud ou être publique. Une seule URL de vidéo YouTube est acceptée par requête.

Lorsque vous spécifiez un `fileURI`, vous devez également indiquer le type de contenu multimédia (`mimeType`) du fichier. Si VPC Service Controls est activé, vous ne pouvez pas spécifier l'URL du fichier multimédia dans `fileURI`.

- *MIME_TYPE* : type de contenu du fichier spécifié dans les champs `data` ou `fileUri`. Les valeurs acceptées incluent les suivantes :

  Cliquer pour développer les types MIME

  - `application/pdf`
  - `audio/mpeg`
  - `audio/mp3`
  - `audio/wav`
  - `image/png`
  - `image/jpeg`
  - `image/webp`
  - `text/plain`
  - `video/mov`
  - `video/mpeg`
  - `video/mp4`
  - `video/mpg`
  - `video/avi`
  - `video/wmv`
  - `video/mpegps`
  - `video/flv`

Méthode HTTP et URL :

```
POST https://LOCATION-aiplatform.googleapis.com/v1/projects/PROJECT_I
```

Corps JSON de la requête :

```
{
  "contents": [{
    "role": "ROLE",
    "parts": [
      {
        "file_data": {
          "file_uri": "FILE_URI",
          "mime_type": "MIME_TYPE"
        }
      },
      {
        "text": "TEXT
      }
    ]
  }]
}
```

Pour envoyer votre requête, choisissez l'une des options suivantes :

curlPowerShell (#powershell)
(#curl)

Remarque : Pour la commande suivante, nous partons du principe que vous vous êtes connecté à la CLI **`gcloud`** avec votre compte utilisateur en exécutant la commande **`gcloud init`** (https://docs.cloud.google.com/sdk/gcloud/reference/init?hl=fr) ou **`gcloud auth login`** (https://docs.cloud.google.com/sdk/gcloud/reference/auth/login?hl=fr), ou en utilisant Cloud Shell (https://docs.cloud.google.com/shell/docs?hl=fr), qui vous connecte automatiquement à la CLI **`gcloud`**. Vous pouvez exécuter la commande **`gcloud auth list`** (https://docs.cloud.google.com/sdk/gcloud/reference/auth/list?hl=fr) pour vérifier quel est le compte actuellement actif.

Enregistrez le corps de la requête dans un fichier nommé **`request.json`**, puis exécutez la commande suivante :

```
curl -X POST \
     -H "Authorization: Bearer $(gcloud auth print-access-token)"
     -H "Content-Type: application/json; charset=utf-8" \
```

```
        -d @request.json \
        "https://LOCATION -aiplatform.googleapis.com/v1/projects/PR
```

Vous devriez recevoir une réponse JSON semblable à la suivante.

Réponse

```
{
  "totalTokens": 31,
  "totalBillableCharacters": 96,
  "promptTokensDetails": [
    {
      "modality": "TEXT","IMAGE"
      "tokenCount": 31
    }
  ]
}
```

Étape suivante

- Apprenez-en plus sur l'API Gemini (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/model-reference/gemini?hl=fr).

Sauf indication contraire, le contenu de cette page est régi par une licence Creative Commons Attribution 4.0 (https://creativecommons.org/licenses/by/4.0/), et les échantillons de code sont régis par une licence Apache 2.0 (https://www.apache.org/licenses/LICENSE-2.0). Pour en savoir plus, consultez les Règles du site Google Developers (https://developers.google.com/site-policies?hl=fr). Java est une marque déposée d'Oracle et/ou de ses sociétés affiliées.

Dernière mise à jour le 2026/02/27 (UTC).