Nano Banana 2 est disponible. Essayez-le dans Google AI Studio. (https://aistudio.google.com/prompts/new_chat?model=gemini-3.1-flash-image-preview&hl=fr)

Tarifs de l'API Gemini Developer

Commencez à créer des applications sans frais avec des limites généreuses, puis évoluez avec la tarification au paiement à l'utilisation pour vos applications prêtes pour la production.

Libre

Pour les développeurs et les petits projets qui débutent avec l'API Gemini.

- Accès limité à certains modèles
- Jetons d'entrée et de sortie sans frais
- Accès à Google AI Studio
- Contenu utilisé pour améliorer nos produits * (https://ai.google.dev/gemini-api/terms?hl=fr)

Profiter d'un essai sans frais (https://aistudio.google.com?hl=fr)

Payant

Pour les applications de production qui nécessitent des volumes plus élevés et des fonctionnalités avancées.

- Limites de débit plus élevées pour les déploiements en production
- Accès à la mise en cache du contexte
- API par lot (réduction des coûts de 50 %)
- Accès aux modèles les plus avancés de Google
- Contenu **non** utilisé pour améliorer nos produits * (https://ai.google.dev/gemini-api/terms?hl=fr)

Passer à un compte payant (https://aistudio.google.com/api-keys?hl=fr)

Enterprise

Pour les déploiements à grande échelle avec des besoins personnalisés en

termes de sécurité, d'assistance et de conformité, optimisés par Vertex AI (https://cloud.google.com/vertex-ai?hl=fr).

- Toutes les fonctionnalités de la version payante, ainsi qu'un accès facultatif à :
- Canaux d'assistance dédiés
- Sécurité et conformité avancées
- Débit provisionné
- Remises basées sur le volume (en fonction de l'utilisation)
- MLOps, Model Garden et plus

Contacter le service commercial
(https://cloud.google.com/contact?hl=fr)

Gemini 3.1 Pro (preview)

gemini-3.1-pro-preview et ***gemini-3.1-pro-preview-customtools***

Essayer dans Google AI Studio (https://aistudio.google.com/prompts/new_chat?model=gemini-3.1-pro-preview&hl=fr)

Les dernières améliorations en termes de performances, d'intelligence et de facilité d'utilisation pour la meilleure famille de modèles au monde en matière de compréhension multimodale, de capacités agentiques et de vibe coding.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Non disponible	2 $, requêtes <= 200 000 jetons 4 $, requêtes > 200 000 jetons
Prix de la sortie (jetons de réflexion inclus)	Non disponible	12 $, requêtes <= 200 000 jetons 18 $, requêtes > 200 000 jetons
Tarifs de la mise en cache du contexte	Non disponible	0,20 $ pour les requêtes <= 200 000 jetons 0,40$pour les requêtes > 200 000 jetons 4,50$pour 1 000 000 de jetons par heure (prix du stockage)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Ancrage avec la recherche Google*	Non disponible	5 000 requêtes par mois (sans frais), puis 14 $pour 1 000 requêtes de recherche
Ancrage avec Google Maps	Non disponible	Non disponible
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

* Une requête envoyée par un client à Gemini peut générer une ou plusieurs requêtes dans la recherche Google. Chaque requête de recherche individuelle effectuée vous sera facturée.

Aperçu de Gemini 3.1 Flash Image 🍌

gemini-3.1-flash-image-preview

Essayer dans Google AI Studio (https://aistudio.google.com/prompts/new_chat?model=gemini-3.1-flash-image-preview&hl=fr)

Conçu pour la rapidité et l'efficacité, le modèle de génération d'images Gemini 3.1 Flash est efficace pour les réponses rapides et interactives, et pour le haut débit.

Les modèles en aperçu peuvent changer avant de devenir stables et avoir des limites de débit plus restrictives.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Non disponible	0,25 $ (texte/image)
Prix de sortie	Non disponible	1,50 $ (texte et réflexion) 60,00 $ (images) Équivaut à 0,045 $par tranche de 0,5 K image* 0,067 $ par tranche de 1 K image*, 0,101 $ par tranche de 2 K image*, et 0,151 $par tranche de 4 K image*.
Ancrage avec la recherche Google**	Non disponible	5 000 requêtes par mois (sans frais), puis 14 $pour 1 000 requêtes de recherche pour l'ancrage basé sur du texte et des images.
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

* Le prix des images générées est de 60 $par tranche de 1 000 000 de jetons. Les images de sortie de 512 px consomment 747 jetons et coûtent 0,045 $par image. Les images de sortie en 1K (1 024 x 1 024 px) consomment 1 120 jetons et coûtent 0,067 $par image. Les images de sortie en 2K (2 048 x 2 048 px) consomment 1 680 jetons et coûtent 0,101 $par image. Les images de sortie en 4K (4 096 x 4 096 px) consomment 2 520 jetons et coûtent 0,151 $par image.

** Une requête envoyée par un client à Gemini peut générer une ou plusieurs requêtes sur la recherche Google. Chaque requête de recherche individuelle effectuée vous sera facturée. Le contexte récupéré (texte ou images) fourni par l'ancrage avec la recherche Google n'est pas facturé en tant que jetons d'entrée.

Gemini 3 Pro Preview

gemini-3-pro-preview

Avertissement : L'aperçu de Gemini 3 Pro est obsolète (https://ai.google.dev/gemini-api/docs/deprecations?hl=fr) et sera arrêté le 9 mars 2026. Migrez vers Gemini 3.1 Pro (preview) (https://ai.google.dev/gemini-api/docs/models/gemini-3.1-pro-preview?hl=fr) pour éviter toute interruption de service.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Non disponible	2 $, requêtes <= 200 000 jetons 4 $, requêtes > 200 000 jetons
Prix de la sortie (jetons de réflexion inclus)	Non disponible	12 $, requêtes <= 200 000 jetons 18 $, requêtes > 200 000 jetons
Tarifs de la mise en cache du contexte	Non disponible	0,20 $ pour les requêtes <= 200 000 jetons 0,40$pour les requêtes > 200 000 jetons 4,50$pour 1 000 000 de jetons par heure (prix du stockage)
Ancrage avec la recherche Google*	Non disponible	5 000 requêtes par mois (sans frais), puis 14 $pour 1 000 requêtes de recherche
Ancrage avec Google Maps	Non disponible	Non disponible
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

* Une requête envoyée par un client à Gemini peut générer une ou plusieurs requêtes dans la recherche Google. Chaque requête de recherche individuelle effectuée vous sera facturée.

Aperçu de Gemini 3 Flash

gemini-3-flash-preview

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-3-flash-preview&hl=fr)

Notre modèle le plus intelligent, conçu pour la rapidité, combine une intelligence de pointe avec des capacités de recherche et d'ancrage supérieures.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	0,50 $ (texte / image / vidéo) 1,00 $ (audio)
Prix de la sortie (jetons de réflexion inclus)	Sans frais	3 $
Tarifs de la mise en cache du contexte	Sans frais	0,05 $ (texte/image/vidéo) 0,10 $ (audio) 1,00$pour 1 000 000 de jetons par heure (prix du stockage)
Ancrage avec la recherche Google*	Non disponible	5 000 requêtes par mois (sans frais), puis 14 $pour 1 000 requêtes de recherche
Ancrage avec Google Maps	Non disponible	Non disponible
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

* Une requête envoyée par un client à Gemini peut générer une ou plusieurs requêtes dans la recherche Google. Chaque requête de recherche individuelle effectuée vous sera facturée.

Aperçu de l'image Gemini 3 Pro 🍌

gemini-3-pro-image-preview

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-3-pro-image-preview&hl=fr)

Notre modèle natif de génération d'images, optimisé pour la vitesse, la flexibilité et la compréhension contextuelle. Les **entrées et sorties textuelles** sont facturées au même prix que Gemini 3 Pro (#gemini-3-pro-preview).

Les modèles en aperçu peuvent changer avant de devenir stables et avoir des limites de débit plus restrictives.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Non disponible	2,00 $ (texte/image), soit 0,0011 $par image*
Prix de sortie	Non disponible	12 $ (texte et réflexion) 120 $ (images) Équivalent à 0,134 $par image 1K/2K** et 0,24 $par image 4K**
Ancrage avec la recherche Google sur le Web et par images***	Non disponible	5 000 requêtes par mois (sans frais), puis 14 $pour 1 000 requêtes de recherche

	Niveau sans frais	Niveau payant, par million de jetons en USD
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

* L'entrée d'image est définie sur 560 jetons ou 0,0011 $par image.

** Le prix des images générées est de 120 $par tranche de 1 000 000 de jetons. Les images de sortie de 1 024 x 1 024 px (1K) à 2 048 x 2 048 px (2K) consomment 1 120 jetons et coûtent 0,134 $par image. Les images de sortie jusqu'à 4 096 x 4 096 px (4K) consomment 2 000 jetons et coûtent 0,24 $par image.

*** Une requête envoyée par un client à Gemini peut générer une ou plusieurs requêtes sur la recherche Google. Chaque requête de recherche individuelle effectuée vous sera facturée.

Gemini 2.5 Pro

`gemini-2.5-pro`

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-2.5-pro&hl=fr)

Notre modèle polyvalent de pointe, qui excelle dans les tâches de codage et de raisonnement complexe.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	1, 25 $ pour les requêtes de moins de 200 000 jetons 2, 50$pour les requêtes de plus de 200 000 jetons
Prix de la sortie (jetons de réflexion inclus)	Sans frais	10 $, requêtes <= 200 000 jetons 15 $, requêtes > 200 000 jetons
Tarifs de la mise en cache du contexte	Non disponible	0,125 $ pour les requêtes <= 200 000 jetons 0,25$pour les requêtes > 200 000 jetons 4,50$pour 1 000 000 de jetons par heure (prix du stockage)
Ancrage avec la recherche Google	Non disponible	1 500 RPD (sans frais), puis 35 $pour 1 000 requêtes ancrées
Ancrage avec Google Maps	Non disponible	10 000 RPD (sans frais), puis 25 $ / 1 000 requêtes ancrées
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Gemini 2.0 Flash

gemini-2.5-flash

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-2.5-flash&hl=fr)

Notre premier modèle de raisonnement hybride, qui accepte une fenêtre de contexte d'un million de jetons et dispose de budgets de réflexion.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	0,30 $ (texte / image / vidéo) 1,00 $ (audio)
Prix de la sortie (jetons de réflexion inclus)	Sans frais	2,50 $
Tarifs de la mise en cache du contexte	Non disponible	0,03 $ (texte/image/vidéo) 0,1 $ (audio) 1$pour 1 000 000 de jetons par heure (prix du stockage)
Ancrage avec la recherche Google	Sans frais, jusqu'à 500 RPD (limite partagée avec les RPD Flash-Lite)	1 500 RPD (sans frais, limite partagée avec les RPD Flash-Lite), puis 35 $ / 1 000 requêtes ancrées
Ancrage avec Google Maps	500 RPD	1 500 RPD (sans frais), puis 25 $pour 1 000 requêtes ancrées
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Gemini 2.5 Flash-Lite

gemini-2.5-flash-lite

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-2.5-flash-lite&hl=fr)

Notre modèle le plus petit et le plus économique, conçu pour une utilisation à grande échelle.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix de l'entrée (texte, image, vidéo)	Sans frais	0,10 $ (texte / image / vidéo) 0,30 $ (audio)
Prix de la sortie (jetons de réflexion inclus)	Sans frais	0,40 $

	Niveau sans frais	Niveau payant, par million de jetons en USD
Tarifs de la mise en cache du contexte	Non disponible	0,01 $ (texte/image/vidéo) 0,03 $ (audio) 1,00$pour 1 000 000 de jetons par heure (prix du stockage)
Ancrage avec la recherche Google	Sans frais, jusqu'à 500 RPD (limite partagée avec les RPD Flash)	1 500 RPJ (sans frais, limite partagée avec les RPJ de Flash), puis 35 $ / 1 000 requêtes ancrées
Ancrage avec Google Maps	500 RPD	1 500 RPD (sans frais), puis 25 $pour 1 000 requêtes ancrées
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Aperçu de Gemini 2.5 Flash-Lite

gemini-2.5-flash-lite-preview-09-2025

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-2.5-flash-lite-preview-09-2025&hl=fr)

Dernier modèle basé sur Gemini 2.5 Flash Lite, optimisé pour la rentabilité, le débit élevé et la haute qualité.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix de l'entrée (texte, image, vidéo)	Sans frais	0,10 $ (texte / image / vidéo) 0,30 $ (audio)
Prix de la sortie (jetons de réflexion inclus)	Sans frais	0,40 $
Tarifs de la mise en cache du contexte	Non disponible	0,01 $ (texte/image/vidéo) 0,03 $ (audio) 1,00$pour 1 000 000 de jetons par heure (prix du stockage)
Ancrage avec la recherche Google	Sans frais, jusqu'à 500 RPD (limite partagée avec les RPD Flash)	1 500 RPJ (sans frais, limite partagée avec les RPJ de Flash), puis 35 $ / 1 000 requêtes ancrées
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Gemini 2.5 Flash Native Audio (API Live)

gemini-2.5-flash-native-audio-preview-12-2025

Essayer dans Google AI Studio (https://aistudio.google.com/app/live?hl=fr#gemini-2.5-flash-native-audio-preview-12-2025)

Nos modèles audio natifs de l'API Live (https://ai.google.dev/gemini-api/docs/live?hl=fr) sont optimisés pour des sorties audio de meilleure qualité, avec un rythme, une voix, une verbosité et une humeur plus naturels.

Les modèles en aperçu peuvent changer avant de devenir stables et avoir des limites de débit plus restrictives.

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	0,50 $ (texte) 3,00 $ (audio / vidéo)
Prix de la sortie (jetons de réflexion inclus)	Sans frais	2,00 $ (texte) 12,00 $ (audio)
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Image Gemini 2.5 Flash 🍌

gemini-2.5-flash-image

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-2.5-flash-image&hl=fr)

Notre modèle natif de génération d'images, optimisé pour la vitesse, la flexibilité et la compréhension contextuelle. Les entrées et sorties textuelles sont facturées au même prix que 2.5 Flash (#gemini-2.5-flash).

Les modèles en aperçu peuvent changer avant de devenir stables et avoir des limites de débit plus restrictives.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Non disponible	0,30 $ (texte / image)
Prix de sortie	Non disponible	0,039 $ par image*
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

[*] La génération d'images est facturée 30 $par tranche de 1 000 000 de jetons. Les images de sortie jusqu'à 1 024 x 1 024 px consomment 1 290 jetons et coûtent 0,039 $par image.

Gemini 2.5 Flash Preview TTS

gemini-2.5-flash-preview-tts

Essayer dans Google AI Studio (https://aistudio.google.com/generate-speech?hl=fr)

Notre modèle audio de synthèse vocale 2.5 Flash est optimisé pour la génération de voix contrôlable, à faible latence et offrant un bon rapport qualité/prix.

Les modèles en aperçu peuvent changer avant de devenir stables et avoir des limites de débit plus restrictives.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	0,50 € (texte)
Prix de sortie	Sans frais	10 $ (audio)
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Gemini 2.5 Pro Preview TTS

gemini-2.5-pro-preview-tts

Essayer dans Google AI Studio (https://aistudio.google.com/generate-speech?hl=fr)

Notre modèle audio de synthèse vocale 2.5 Pro est optimisé pour générer des voix puissantes et à faible latence, pour des résultats plus naturels et des requêtes plus faciles à orienter.

Les modèles en aperçu peuvent changer avant de devenir stables et avoir des limites de débit plus restrictives.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Non disponible	1,00 $ (texte)
Prix de sortie	Non disponible	20,00 $ (audio)
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Gemini 2.0 Flash

gemini-2.0-flash

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-2.0-flash&hl=fr)

Notre modèle multimodal le plus équilibré, qui offre d'excellentes performances pour toutes les tâches, avec une fenêtre de contexte d'un million de jetons. Il est conçu pour l'ère des agents.

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	0,10 $ (texte / image / vidéo) 0,70 $ (audio)
Prix de sortie	Sans frais	0,40 $
Tarifs de la mise en cache du contexte	Sans frais	0,025 $ pour 1 000 000 de jetons (texte/image/vidéo) 0,175$pour 1 000 000 de jetons (audio)
Mise en cache du contexte (stockage)	Non disponible	1 $ / 1 000 000 de jetons par heure
Tarifs de la génération d'images	Sans frais	0,039 $ par image*
Prix de l'optimisation	Non disponible	Non disponible
Ancrage avec la recherche Google	Sans frais, jusqu'à 500 RPD	1 500 RPD (sans frais), puis 35 $pour 1 000 requêtes ancrées
Ancrage avec Google Maps	500 RPD	1 500 RPD (sans frais), puis 25 $pour 1 000 requêtes ancrées
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

[*] La génération d'images est facturée 30 $par tranche de 1 000 000 de jetons. Les images de sortie jusqu'à 1 024 x 1 024 px consomment 1 290 jetons et coûtent 0,039 $par image.

Gemini 2.0 Flash-Lite

gemini-2.0-flash-lite

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-2.0-flash-lite&hl=fr)

Notre modèle le plus petit et le plus économique, conçu pour une utilisation à grande échelle.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	0,075 $
Prix de sortie	Sans frais	0,30 $
Tarifs de la mise en cache du contexte	Non disponible	Non disponible
Mise en cache du contexte (stockage)	Non disponible	Non disponible
Prix de l'optimisation	Non disponible	Non disponible

	Niveau sans frais	Niveau payant, par million de jetons en USD
Ancrage avec la recherche Google	Non disponible	Non disponible
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Imagen 4

`imagen-4.0-generate-001`, `imagen-4.0-ultra-generate-001`, `imagen-4.0-fast-generate-001`

Essayer dans Google AI Studio (https://aistudio.google.com/generate-image?hl=fr)

Notre dernier modèle de génération d'images, avec un rendu de texte et une qualité d'image globale nettement améliorés.

Les modèles en aperçu peuvent changer avant de devenir stables et avoir des limites de débit plus restrictives.

	Niveau sans frais	Niveau payant, par image en USD
Prix des images Imagen 4 Fast	Non disponible	0,02 $
Prix des images standards Imagen 4	Non disponible	0,04 $
Prix des images Imagen 4 Ultra	Non disponible	0,06 $
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Veo 3.1

`veo-3.1-generate-preview`, `veo-3.1-fast-generate-preview`

Essayer Veo 3.1 (https://deepmind.google/models/veo/?hl=fr)

Notre dernier modèle de génération de vidéos, disponible pour les développeurs au niveau payant de l'API Gemini.

Les modèles en aperçu peuvent changer avant de devenir stables et avoir des limites de débit plus restrictives.

	Niveau sans frais	Niveau payant, par seconde en USD
Prix par défaut pour une vidéo Veo 3.1 Standard avec audio	Non disponible	0,40 $ (720p et 1080p) 0,60 $ (4K)
Prix par défaut pour une vidéo Veo 3.1 Fast avec audio	Non disponible	0,15 $ (720p et 1080p) 0,35 $ (4K)

	Niveau sans frais	Niveau payant, par seconde en USD
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Remarque : Dans certains cas, un problème de traitement audio peut empêcher la génération d'une vidéo. Vous ne serez facturé que si votre vidéo est générée avec succès.

Veo 3

`veo-3.0-generate-001`, `veo-3.0-fast-generate-001`

Essayer Veo 3 (https://deepmind.google/models/veo/?hl=fr)

Notre modèle stable de génération de vidéos, disponible pour les développeurs dans le niveau payant de l'API Gemini.

	Niveau sans frais	Niveau payant, par seconde en USD
Prix de la vidéo Veo 3 Standard avec audio (par défaut)	Non disponible	0,40 $
Prix par défaut pour une vidéo Veo 3 Fast avec audio	Non disponible	0,15 $
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Remarque : Dans certains cas, un problème de traitement audio peut empêcher la génération d'une vidéo. Vous ne serez facturé que si votre vidéo est générée avec succès.

Veo 2

`veo-2.0-generate-001`

Essayer l'API (https://ai.google.dev/gemini-api/docs/video?hl=fr)

Notre modèle de génération de vidéos de pointe, disponible pour les développeurs avec le forfait payant de l'API Gemini.

	Niveau sans frais	Niveau payant, par seconde en USD
Prix de la vidéo	Non disponible	0,35 $

	Niveau sans frais	Niveau payant, par seconde en USD
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Embedding Gemini

gemini-embedding-001

Essayer l'API (https://ai.google.dev/gemini-api/docs/embeddings?hl=fr)

Notre dernier modèle d'embeddings, plus stable et avec des limites de débit plus élevées que les versions précédentes, est disponible pour les développeurs dans les niveaux sans frais et payant de l'API Gemini.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	0,15 $
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Gemini Robotics-ER 1.5 (preview)

gemini-robotics-er-1.5-preview

Essayer dans Google AI Studio (https://aistudio.google.com?model=gemini-robotics-er-1.5-preview&hl=fr)

Gemini Robotics-ER, abréviation de Gemini Robotics-Embodied Reasoning, est un modèle de réflexion qui améliore la capacité des robots à comprendre le monde physique et à interagir avec lui.

StandardLot (#lot)
(#standard)

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	0,30 $ (texte / image / vidéo) 1,00 $ (audio)
Prix de la sortie (jetons de réflexion inclus)	Sans frais	2,50 $
Ancrage avec la recherche Google	Sans frais, jusqu'à 500 RPD (limite partagée avec les RPD Flash-Lite)	1 500 RPD (sans frais, limite partagée avec les RPD Flash-Lite), puis 35 $ / 1 000 requêtes ancrées

	Niveau sans frais	Niveau payant, par million de jetons en USD
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Aperçu de Gemini 2.5 Computer Use

`gemini-2.5-computer-use-preview-10-2025`

Notre modèle d'utilisation de l'ordinateur est optimisé pour la création d'agents de contrôle du navigateur qui automatisent les tâches.

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Non disponible	1,25 $, requêtes <= 200 000 jetons 2,50 $, requêtes > 200 000 jetons
Prix de sortie	Non disponible	10 $, requêtes <= 200 000 jetons 15 $, requêtes > 200 000 jetons
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Gemma 3

Notre modèle ouvert, léger et de pointe, basé sur la même technologie que celle de nos modèles Gemini.

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	Non disponible
Prix de sortie	Sans frais	Non disponible
Tarifs de la mise en cache du contexte	Sans frais	Non disponible
Mise en cache du contexte (stockage)	Sans frais	Non disponible
Prix de l'optimisation	Non disponible	Non disponible
Ancrage avec la recherche Google	Non disponible	Non disponible
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Gemma 3n

Notre modèle ouvert conçu pour des performances efficaces sur les appareils du quotidien tels que les téléphones mobiles, les ordinateurs portables et les tablettes.

	Niveau sans frais	Niveau payant, par million de jetons en USD
Prix d'entrée	Sans frais	Non disponible
Prix de sortie	Sans frais	Non disponible
Tarifs de la mise en cache du contexte	Sans frais	Non disponible
Mise en cache du contexte (stockage)	Sans frais	Non disponible
Prix de l'optimisation	Non disponible	Non disponible
Ancrage avec la recherche Google	Non disponible	Non disponible
Utilisées pour améliorer nos produits	Oui (https://ai.google.dev/gemini-api/terms?hl=fr)	Non (https://ai.google.dev/gemini-api/terms?hl=fr)

Tarifs des outils

Les outils sont facturés à leur propre tarif, appliqué au modèle qui les utilise. Consultez la page Modèles (https://ai.google.dev/gemini-api/docs/models?hl=fr) pour connaître les outils disponibles pour chaque modèle.

	Niveau sans frais	Niveau payant, par million de jetons en USD
La recherche Google (https://ai.google.dev/gemini-api/docs/google-search?hl=fr#pricing)	500 RPD sans frais (limite partagée pour Flash et Flash-Lite). Non disponible pour Pro.	Modèles Gemini 2.5 : 1 500 RPD sans frais (limite partagée pour Flash et Flash-Lite). Puis 35 $ / 1 000 requêtes ancrées Modèles Gemini 3 : 5 000 requêtes par mois (sans frais), puis 14 $ / 1 000 requêtes de recherche
Google Maps (https://ai.google.dev/gemini-api/docs/maps-grounding?hl=fr#pricing_and_rate_limits)	500 RPD Non disponible pour Pro.	1 500 RPD sans frais (limite partagée pour Flash et Flash-Lite) 10 000 RPD sans frais pour Pro. Puis 25 $pour 1 000 requêtes ancrées
Exécution de code (https://ai.google.dev/gemini-api/docs/code-execution?hl=fr#billing)	Sans frais	L'exécution de code est facturée aux tarifs standards des jetons pour le modèle sélectionné. Les coûts sont déterminés uniquement par l'utilisation de l'outil. Aucun frais n'est facturé pour la durée d'exécution de la session. Le code généré et les résultats de l'exécution sont facturés en tant que **jetons de sortie** lors de leur création, et en tant que **jetons d'entrée** lorsque le modèle les utilise dans le cadre de son processus de raisonnement itératif.

	Niveau sans frais	Niveau payant, par million de jetons en USD
Contexte de l'URL (https://ai.google.dev/gemini-api/docs/url-context?hl=fr#limitations)	Sans frais	Facturé en tant que jetons d'entrée selon la tarification par modèle.
Utilisation de l'ordinateur (https://ai.google.dev/gemini-api/docs/computer-use?hl=fr)	Non disponible	Consultez le tableau des tarifs de l'aperçu de Gemini 2.5 Computer Use (#gemini-2.5-computer-use-preview-10-2025) .
Recherche de fichiers (https://ai.google.dev/gemini-api/docs/file-search?hl=fr#pricing)	Sans frais	Les embeddings (#gemini-embedding) sont facturés 0,15 $par million de jetons. Les jetons de documents récupérés sont facturés comme des jetons standards, selon la tarification du modèle.
Point de terminaison Custom Tools (version preview de Gemini 3.1 Pro) (https://ai.google.dev/gemini-api/docs/models/gemini-3.1-pro-preview?hl=fr)	Non disponible	Identique aux tarifs de Gemini 3.1 Pro Preview (#gemini-3.1-pro-preview)

[*] L'utilisation de Google AI Studio est sans frais dans toutes les régions disponibles (https://ai.google.dev/gemini-api/docs/available-regions?hl=fr). Pour en savoir plus, consultez les questions fréquentes sur la facturation (https://ai.google.dev/gemini-api/docs/billing?hl=fr).

[**] Les prix peuvent différer de ceux indiqués ici et de ceux proposés sur Vertex AI. Pour connaître les tarifs de Vertex, consultez la page Tarification de Vertex AI (https://cloud.google.com/vertex-ai/generative-ai/pricing?hl=fr).

[***] Si vous utilisez la récupération dynamique (https://ai.google.dev/gemini-api/docs/grounding?hl=fr) pour optimiser les coûts, seuls les demandes qui contiennent au moins une URL d'ancrage du Web dans leur réponse sont facturées pour l'ancrage avec la recherche Google. Les coûts de Gemini s'appliquent toujours. Les limites de débit sont susceptibles d'être modifiées.

Tarifs pour les agents

Les coûts d'utilisation des agents sont calculés en fonction de la consommation de jetons sous-jacente et de l'utilisation des outils.

	Modèle	Outils
Agent Gemini Deep Research (https://ai.google.dev/gemini-api/docs/deep-research?hl=fr)	Toute inférence de modèle est facturée aux tarifs standards Gemini 3 Pro (#gemini-3-pro-preview), y compris les jetons d'entrée, de sortie et d'entrée / de raisonnement intermédiaires générés lors des boucles agentiques.	Les frais d'utilisation des outils s'appliquent selon la structure tarifaire existante, en conservant les distinctions standards entre l'ancrage de recherche (jetons récupérés exclus) et la recherche dans le contexte d'URL / de fichier (jetons récupérés inclus dans tous les autres outils).

Sauf indication contraire, le contenu de cette page est régi par une licence Creative Commons Attribution 4.0 (https://creativecommons.org/licenses/by/4.0/), et les échantillons de code sont régis par une licence Apache 2.0 (https://www.apache.org/licenses/LICENSE-2.0). Pour en savoir plus, consultez les Règles du site Google Developers (https://developers.google.com/site-policies?hl=fr). Java est une marque déposée d'Oracle et/ou de ses sociétés affiliées.

Dernière mise à jour le 2026/02/26 (UTC).