Utiliser les instructions système

Ce document explique comment utiliser les instructions système. Pour découvrir en quoi consistent les instructions système et les bonnes pratiques liées à leur utilisation, consultez plutôt Présentation des instructions système (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/learn/prompts/system-instruction-introduction?hl=fr)
.

Les instructions système sont un ensemble d'instructions que le modèle traite avant de traiter les requêtes. Nous vous recommandons d'utiliser des instructions système pour indiquer au modèle comment vous souhaitez qu'il se comporte et qu'il réponde aux requêtes. Par exemple, vous pouvez inclure des éléments tels que le rôle ou le persona, des informations contextuelles et des instructions de mise en forme :

```
You are a friendly and helpful assistant.
Ensure your answers are complete, unless the user requests a more concise approach
When generating code, offer explanations for code segments as necessary and mainta
When presented with inquiries seeking information, provide answers that reflect a
For any non-english queries, respond in the same language as the prompt unless oth
For prompts involving reasoning, provide a clear explanation of each step in the r
```

Lorsqu'une instruction système est définie, elle s'applique à l'ensemble de la requête. Elle fonctionne sur plusieurs tours d'utilisateur et de modèle lorsqu'elle est incluse dans le prompt. Bien que les instructions système soient distinctes du contenu du prompt, elles font toujours partie de vos prompts globales et sont donc soumises aux règles standards d'utilisation des données.

Remarque : Les instructions système peuvent aider le modèle à suivre les instructions, mais elles n'empêchent pas complètement les jailbreaks ou les fuites. Nous vous recommandons de faire preuve de prudence lorsque vous insérez des informations sensibles dans les instructions système.

Cas d'utilisation

Vous pouvez utiliser les instructions système de différentes manières, par exemple :

- Pour définir un persona ou un rôle (pour un chatbot, par exemple)
- Pour définir le format de sortie (Markdown, YAML, etc.)

- Pour définir le style et le ton de la sortie (par exemple, la verbosité, la formalité et le niveau de lecture cible)
- Pour définir des objectifs ou des règles pour la tâche (par exemple, renvoyer un extrait de code sans autre explication)
- Pour fournir un contexte supplémentaire pour le prompt (par exemple, une date limite des connaissances)
- Pour spécifier la langue dans laquelle le modèle doit répondre (parfois, les modèles peuvent répondre dans votre langue locale, même si le prompt est écrit dans une autre langue). Si vous utilisez une langue autre que l'anglais pour vos requêtes, nous vous recommandons d'ajouter ceci à vos instructions système :

```
All questions should be answered comprehensively with details, unless the use
```

Exemples de code

Les exemples de code des onglets suivants montrent comment utiliser des instructions système dans votre application d'IA générative.

Python Gen AI SDK | Go Gen AI SDK | Node.js Gen AI SDK | Java Gen AI SDK | REST

Une fois que vous avez configuré votre environnement (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/start/quickstarts/quickstart-multimodal?hl=fr#gemini-setup-environment-drest), vous pouvez utiliser REST pour tester un prompt textuel. L'exemple suivant envoie une requête au point de terminaison du modèle de l'éditeur.

Avant d'utiliser les données de requête, effectuez les remplacements suivants :

- *GENERATE_RESPONSE_METHOD* : type de réponse que le modèle doit générer. Choisissez la méthode de renvoi de la réponse du modèle :
  - `streamGenerateContent` : la réponse s'affiche progressivement à mesure qu'elle est générée afin que les utilisateurs ressentent moins la latence.
  - `generateContent` : la réponse est renvoyée une fois qu'elle a été entièrement générée.
- *LOCATION* : région dans laquelle traiter la requête. Les options disponibles incluent les suivantes :

Cliquer pour développer la liste partielle des régions disponibles

- `us-central1`
- `us-west4`
- `northamerica-northeast1`
- `us-east4`
- `us-west1`
- `asia-northeast3`
- `asia-southeast1`
- `asia-northeast1`

- *`PROJECT_ID`* : ID de votre projet. (https://docs.cloud.google.com/resource-manager/docs/creating-managing-projects?hl=fr#identifiers)
- *`MODEL_ID`* : ID du modèle multimodal que vous souhaitez utiliser.
- *`ROLE`* : rôle dans une conversation associée au contenu. La spécification d'un rôle est requise, même dans les cas d'utilisation à un seul tour. Les valeurs acceptées incluent les suivantes :
  - `USER` : spécifie le contenu que vous envoyez.
  - `MODEL` : spécifie la réponse du modèle.

- *`TEXT`*

  Instructions textuelles à inclure dans le prompt. Exemple : `User input: I like bagels`

- *`SAFETY_CATEGORY`* : catégorie de sécurité pour laquelle configurer un seuil. Les valeurs acceptées incluent les suivantes :

  Cliquer pour développer les catégories de sécurité

  - `HARM_CATEGORY_SEXUALLY_EXPLICIT`
  - `HARM_CATEGORY_HATE_SPEECH`
  - `HARM_CATEGORY_HARASSMENT`
  - `HARM_CATEGORY_DANGEROUS_CONTENT`

- *THRESHOLD* : seuil de blocage des réponses susceptibles d'appartenir à la catégorie de sécurité spécifiée en fonction de la probabilité. Les valeurs acceptées incluent les suivantes :

  Cliquer pour développer les seuils de blocage

  - `BLOCK_NONE`
  - `BLOCK_ONLY_HIGH`
  - `BLOCK_MEDIUM_AND_ABOVE` (par défaut)
  - `BLOCK_LOW_AND_ABOVE`

  `BLOCK_LOW_AND_ABOVE` bloque le plus, tandis que `BLOCK_ONLY_HIGH` bloque le moins.

- *SYSTEM_INSTRUCTION*

  (Facultatif) Non disponible pour tous les modèles. Instructions destinées au modèle afin de l'orienter vers de meilleures performances. Le format JSON n'est pas compatible avec les sauts de ligne. Remplacez tous les sauts de ligne de ce champ par `\n`. Par exemple : `You are a helpful language translator.\nYour mission is to translate text in English to French.`

- *TEMPERATURE* : la température est utilisée pour l'échantillonnage pendant la génération des réponses, qui se produit lorsque `topP` et `topK` sont appliqués. La température permet de contrôler le degré de hasard dans la sélection des jetons. Les températures inférieures sont idéales pour les requêtes qui nécessitent une réponse moins ouverte ou créative, tandis que des températures plus élevées peuvent conduire à des résultats plus diversifiés ou créatifs. Une température de `0` signifie que les jetons de probabilité les plus élevés sont toujours sélectionnés. Dans ce cas, les réponses pour une requête donnée sont principalement déterministes, mais une petite quantité de variation est toujours possible.

  Si le modèle renvoie une réponse trop générique ou trop courte, ou s'il renvoie une réponse de remplacement, essayez d'augmenter la température. Si le modèle entre dans une génération infinie, augmenter la température à au moins `0.1` peut améliorer les résultats.

  `1.0` est la valeur de départ recommandée pour la température.

- *TOP_P* : top-P modifie la façon dont le modèle sélectionne les jetons pour la sortie. Les jetons sont sélectionnés de la probabilité la plus élevée à la probabilité la plus faible jusqu'à ce que la somme de leurs probabilités soit égale à la valeur top-P. Par exemple, si les jetons A, B et C ont une probabilité de 0,3, 0,2 et 0,1 et que la

valeur de top-P est `0.5`, le modèle sélectionne A ou B comme jeton suivant à l'aide de la température et exclut le jeton C comme candidat.

Spécifiez une valeur inférieure pour obtenir des réponses moins aléatoires et une valeur supérieure pour des réponses plus aléatoires.

- *`TOP_K`* : top-K modifie la façon dont le modèle sélectionne les jetons pour la sortie. Une valeur top-K de `1` signifie que le prochain jeton sélectionné est le plus probable parmi tous les jetons du vocabulaire du modèle (une stratégie également appelée décodage glouton), tandis qu'une valeur top-K de `3` signifie que le jeton suivant est sélectionné parmi les trois jetons les plus probables à l'aide de la température.

  Pour chaque étape de sélection du jeton, les jetons top-K avec les probabilités les plus élevées sont échantillonnés. Les jetons sont ensuite filtrés en fonction du top-P avec le jeton final sélectionné à l'aide de l'échantillonnage de température.

  Spécifiez une valeur inférieure pour obtenir des réponses moins aléatoires et une valeur supérieure pour des réponses plus aléatoires.

- *`MAX_OUTPUT_TOKENS`* : le nombre maximal de jetons pouvant être générés dans la réponse. Un jeton correspond environ à quatre caractères. 100 jetons correspondent à environ 60-80 mots.

  Spécifiez une valeur inférieure pour obtenir des réponses plus courtes et une valeur supérieure pour des réponses potentiellement plus longues.

- *`STOP_SEQUENCES`* : spécifie une liste de chaînes qui indiquent au modèle d'arrêter de générer du texte si l'une des chaînes est détectée dans la réponse. Si une chaîne apparaît plusieurs fois dans la réponse, celle-ci effectue une troncation lors de la première rencontre. Les chaînes sont sensibles à la casse.

  Par exemple, si la réponse suivante est renvoyée lorsque `stopSequences` n'est pas spécifié :

  ```
  public static string reverse(string myString)
  ```

  La réponse renvoyée avec `stopSequences` défini sur `["Str", "reverse"]` est alors la suivante :

  ```
  public static string
  ```

  Spécifiez un tableau vide (`[]`) pour désactiver les séquences d'arrêt.

Pour envoyer votre requête, choisissez l'une des options suivantes :

★ **Remarque** : Pour la commande suivante, nous partons du principe que vous vous êtes connecté à la CLI **`gcloud`** avec votre compte utilisateur en exécutant la commande **`gcloud init`** (https://docs.cloud.google.com/sdk/gcloud/reference/init?hl=fr) ou **`gcloud auth login`** (https://docs.cloud.google.com/sdk/gcloud/reference/auth/login?hl=fr), ou en utilisant Cloud Shell (https://docs.cloud.google.com/shell/docs?hl=fr), qui vous connecte automatiquement à la CLI **`gcloud`**. Vous pouvez exécuter la commande **`gcloud auth list`** (https://docs.cloud.google.com/sdk/gcloud/reference/auth/list?hl=fr) pour vérifier quel est le compte actuellement actif.

Enregistrez le corps de la requête dans un fichier nommé **`request.json`**. Exécutez la commande suivante dans le terminal pour créer ou écraser ce fichier dans le répertoire actuel :

```
cat > request.json << 'EOF'
{
  "contents": {
    "role": "ROLE",
    "parts": { "text": "TEXT" }
  },
  "system_instruction":
  {
    "parts": [
      {
        "text": "SYSTEM_INSTRUCTION"
      }
    ]
  },
  "safety_settings": {
    "category": "SAFETY_CATEGORY",
    "threshold": "THRESHOLD"
  },
  "generation_config": {
    "temperature": TEMPERATURE,
    "topP": TOP_P,
    "topK": TOP_K,
    "candidateCount": 1,
    "maxOutputTokens": MAX_OUTPUT_TOKENS,
    "stopSequences": STOP_SEQUENCES
  }
}
EOF
```

Exécutez ensuite la commande suivante pour envoyer votre requête REST :

```
curl -X POST \
     -H "Authorization: Bearer $(gcloud auth print-access-token)" \
     -H "Content-Type: application/json; charset=utf-8" \
     -d @request.json \
     "https://LOCATION -aiplatform.googleapis.com/v1/projects/PROJECT
```

Vous devriez recevoir une réponse JSON semblable à la suivante.

Réponse


```
{
  "candidates": [
    {
      "content": {
        "role": "model",
        "parts": [
          {
            "text": "J'aime les bagels. \n"
          }
        ]
      },
      "finishReason": "STOP",
      "safetyRatings": [
        {
          "category": "HARM_CATEGORY_HATE_SPEECH",
          "probability": "NEGLIGIBLE",
          "probabilityScore": 0.1481704,
          "severity": "HARM_SEVERITY_NEGLIGIBLE",
          "severityScore": 0.07921032
        },
        {
          "category": "HARM_CATEGORY_DANGEROUS_CONTENT",
          "probability": "NEGLIGIBLE",
          "probabilityScore": 0.07185127,
          "severity": "HARM_SEVERITY_NEGLIGIBLE",
          "severityScore": 0.10302442
        },
        {
          "category": "HARM_CATEGORY_HARASSMENT",
          "probability": "NEGLIGIBLE",
          "probabilityScore": 0.11920293,
          "severity": "HARM_SEVERITY_NEGLIGIBLE",
          "severityScore": 0.07626997
        },
        {
```

```
            "category": "HARM_CATEGORY_SEXUALLY_EXPLICIT",
            "probability": "NEGLIGIBLE",
            "probabilityScore": 0.20212802,
            "severity": "HARM_SEVERITY_NEGLIGIBLE",
            "severityScore": 0.13386749
          }
        ]
      }
    ],
    "usageMetadata": {
      "promptTokenCount": 25,
      "candidatesTokenCount": 8,
      "totalTokenCount": 33
    }
  }
```

Notez les points suivants dans l'URL de cet exemple :

- Utilisez la méthode **`generateContent`** (https://docs.cloud.google.com/vertex-ai/docs/reference/rest/v1/projects.locations.publishers.models/generateContent?hl=fr) pour demander que la réponse soit renvoyée une fois qu'elle a été entièrement générée. Pour réduire la perception de la latence auprès d'un public humain, affichez la réponse progressivement à mesure qu'elle est générée à l'aide de la méthode **`streamGenerateContent`** (https://docs.cloud.google.com/vertex-ai/docs/reference/rest/v1/projects.locations.publishers.models/streamGenerateContent?hl=fr) .
- L'ID du modèle multimodal se trouve à la fin de l'URL avant la méthode (par exemple, **`gemini-2.0-flash`**). Cet exemple peut également s'appliquer à d'autres modèles.
- Lorsque vous utilisez un point de terminaison d'API régional (par exemple, **`us-central1`**), la région de l'URL du point de terminaison détermine où la requête est traitée. Tout emplacement en conflit dans le chemin d'accès aux ressources est ignoré.

Exemples d'invites

Vous trouverez ci-dessous des exemples de requêtes système qui définissent le comportement attendu du modèle.

Génération de code

ation de code

:ions système :

```
ıre a coding expert that specializes in rendering code for front-end interfaces. Wh
·ibe a component of a website I want to build, please return the HTML and CSS neede
). Do not give an explanation for this code. Also offer some UI design suggestions.
```

:

```
:e a box in the middle of the page that contains a rotating selection of images eac
 a caption. The image in the center of the page should have shadowing behind it to
:and out. It should also link to another page of the site. Leave the URL blank so t
ı fill it in.
```

Génération de données formatées

ation de données formatées

:ions système :

```
ıre an assistant for home cooks. You receive a list of ingredients and respond with
 of recipes that use those ingredients. Recipes which need no extra ingredients sho
/s be listed before those that do.

 response must be a JSON object containing 3 recipes. A recipe object has the follo
ıa:

ıe: The name of the recipe
edIngredients: Ingredients in the recipe that were provided in the list
ıerIngredients: Ingredients in the recipe that were not provided in the
 (omitted if there are no other ingredients)
scription: A brief description of the recipe, written positively as if
ell it
```

:

```
.b bag frozen broccoli
oint heavy cream
```

.b pack cheese ends and pieces

Chatbot de musique

ɔt de musique

:ions système :

```
vill respond as a music historian, demonstrating comprehensive knowledge across div
:al genres and providing relevant examples. Your tone will be upbeat and enthusiast
ıding the joy of music. If a question is not related to music, the response should
: is beyond my knowledge."
```

:

```
 person was born in the sixties, what was the most popular music genre being played
 they were born? List five songs by bullet point.
```

Analyse financière

se financière

:ions système :

```
 financial analysis expert, your role is to interpret complex financial data, offer
ɔnalized advice, and evaluate investments using statistical methods to gain insight
ss different financial areas.

·acy is the top priority. All information, especially numbers and calculations, mus
ect and reliable. Always double-check for errors before giving a response. The way
ɔnd should change based on what the user needs. For tasks with calculations or data
ysis, focus on being precise and following instructions rather than giving long
ınations. If you're unsure, ask the user for more information to ensure your respon
s their needs.

:asks that are not about numbers:

e clear and simple language to avoid confusion and don't use jargon.
```

```
:e sure you address all parts of the user's request and provide complete informatic
.nk about the user's background knowledge and provide additional context or explana
 needed.

ıtting and Language:

.low any specific instructions the user gives about formatting or language.
ɜ proper formatting like JSON or tables to make complex data or results easier to
·stand.
```

:

```
ɜe summarize the key insights of given numerical tables.

)LIDATED STATEMENTS OF INCOME (In millions, except per share amounts)

· Ended December 31 | 2020 | 2021 | 2022 |

 | --- | --- | --- |

ɜnues | $ 182,527| $ 257,637| $ 282,836|

:s and expenses:|

: of revenues | 84,732 | 110,939 | 126,203|

ɜarch and development | 27,573 | 31,562 | 39,500|

ɜs and marketing | 17,946 | 22,912 | 26,567|

ɜral and administrative | 11,052 | 13,510 | 15,724|

ıl costs and expenses | 141,303| 178,923| 207,994|

ɔme from operations | 41,224 | 78,714 | 74,842|

ɜr income (expense), net | 6,858 | 12,020 | (3,514)|

ɔme before income taxes | 48,082 | 90,734 | 71,328|

ʼision for income taxes | 7,813 | 14,701 | 11,356|

 income | $40,269| $76,033 | $59,972|

.c net income per share of Class A, Class B, and Class C stock | $2.96| $5.69| $4.5

ıted net income per share of Class A, Class B, and Class C stock| $2.93| $5.61| $4.
```

```
se list important, but no more than five, highlights from 2020 to 2022 in the given
e.

se write in a professional and business-neutral tone.

summary should only be based on the information presented in the table.
```

Analyse des sentiments du marché

se des sentiments du marché

ions système :

```
are a stock market analyst who analyzes market sentiment given a news snippet. Base
news snippet, you extract statements that impact investor sentiment.

ond in JSON format and for each statement:

ve a score 1 - 10 to suggest if the sentiment is negative or positive (1 is most
tive 10 is most positive, 5 will be neutral).
terate the statement.
ve a one sentence explanation.
```

:

```
eye reported a build-up of excess inventory by top-tier customers following supply
n constraints in
nt years. Revenue for the first quarter is expected to be down about 50% from $458
on generated a
 earlier, before normalizing over the remainder of 2024, Mobileye said. Mobileye
cast revenue for
-year 2024 at between $1.83 billion and $1.96 billion, down from the about $2.08
on it now expects for 2023.
```

Étape suivante

- Découvrez d'autres exemples de requêtes dans la galerie de requêtes (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/prompt-gallery?hl=fr).

Sauf indication contraire, le contenu de cette page est régi par une licence Creative Commons Attribution 4.0 (https://creativecommons.org/licenses/by/4.0/), et les échantillons de code sont régis par une licence Apache 2.0 (https://www.apache.org/licenses/LICENSE-2.0). Pour en savoir plus, consultez les Règles du site Google Developers (https://developers.google.com/site-policies?hl=fr). Java est une marque déposée d'Oracle et/ou de ses sociétés affiliées.

Dernière mise à jour le 2026/02/27 (UTC).